

Szeregowanie zadań. Dowody optymalności kodów Huffmana – Wykład

1 Prostý problem szeregowania zadań

$\{z_1, z_2, \dots, z_n\}$ – zbiór zadań.

Każde zadanie z_i ma swój czas wykonania t_i , $i \in [n]$.

Rozpoczęte zadanie nie może być przerwane.

1.1 Problem 1

Mamy jeden procesor.

Jak uszeregować zadania tak, aby średni czas ukończenia był jak najmniejszy?

Przykład 1.

i	zadanie	t_i
1	z_1	15
2	z_2	8
3	z_3	3
4	z_4	10

Kolejność z_1, z_2, z_3, z_4 :

$$\frac{15 + (15 + 8) + (15 + 8 + 3) + (15 + 8 + 3 + 10)}{4} = \frac{15 + 23 + 26 + 36}{4} = \frac{100}{4} = 25$$

Kolejność z_3, z_2, z_4, z_1 (od najkrótszego do najdłuższego):

$$\frac{3 + (3 + 8) + (3 + 8 + 10) + (3 + 8 + 10 + 15)}{4} = \frac{3 + 11 + 21 + 36}{4} = \frac{71}{4} = 17,75$$

Rozwiązanie: Przydzielaj zadania do procesora w kolejności od najkrótszego do najdłuższego.

1.2 Problem 2

Mamy 3 procesory.

Pytanie: jak poprawnie?

Przykład 2.

zadanie	z_1	z_2	z_3	z_4	z_5	z_6	z_7	z_8
t_i	3	5	6	10	11	15	18	20

Rozwiązanie: Przydzielaj zadania do pierwszego wolnego procesora w kolejności od najkrótszego do najdłuższego.

Przydział na 3 procesory:

- P_1 : z_1 (3), z_4 (10), z_7 (18)
- P_2 : z_2 (5), z_5 (11), z_8 (20)
- P_3 : z_3 (6), z_6 (15)

1.3 Dowód poprawności

Zatem $f(\Pi') \leq f(\Pi)$, ale Π minimalizuje f , więc $f(\Pi') = f(\Pi)$ i Π' też minimalizuje f .

Po pewnej liczbie takich zamian otrzymujemy permutację $\Pi_0 = (j_1, \dots, j_n)$ minimalizującą f taką, że

$$t_{j_1} \leq t_{j_2} \leq \dots \leq t_{j_n}$$

Wniosek 1. Nasz algorytm szeregowania zadań jest poprawny.

2 Dowody optymalności kodów Huffmana

Kody prefiksowe $\longleftrightarrow$ regularne drzewa binarne.

C – alfabet, $f: C \rightarrow \mathbb{N}$ – funkcja częstości, $d_T(c)$ – głębokość liścia reprezentującego znak c w drzewie T reprezentującym kod prefiksowy.

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c) \longleftarrow \min$$

Lemat 1. Niech x i y będą najrzadziej występującymi znakami z C . Istnieje optymalny kod prefiksowy, w którym słowa kodowe x i y mają tę samą długość i różnią się tylko na ostatnim bicie.

Dowód. Znajdziemy drzewo reprezentujące optymalny kod prefiksowy, w którym liście reprezentujące x i y mają wspólnego rodzica i mają największą głębokość w drzewie.

Niech T będzie dowolnym drzewem reprezentującym optymalny kod prefiksowy i niech a i b będą dwoma liśćmi o tym samym rodzicu i największej głębokości w T .

Bez straty ogólności możemy przyjąć, że $f(x) \leq f(y)$ i $f(a) \leq f(b)$.

$f(x)$ i $f(y)$ są najmniejszymi częstościami, więc $f(x) \leq f(a)$ i $f(y) \leq f(b)$.

Niech T' będzie drzewem powstałym z T przez zamianę liści x i a .

$$\begin{aligned} B(T) - B(T') &= \sum_{c \in C} f(c) d_T(c) - \sum_{c \in C} f(c) d_{T'}(c) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_{T'}(a) - f(x) d_{T'}(x) \\ &= f(a) d_T(a) + f(x) d_T(x) - f(a) d_T(x) - f(x) d_T(a) \\ &= f(a)(d_T(a) - d_T(x)) - f(x)(d_T(a) - d_T(x)) \\ &= (f(a) - f(x))(d_T(a) - d_T(x)) \geq 0 \end{aligned}$$

(bo $f(a) \geq f(x)$ i $d_T(a) \geq d_T(x)$, gdyż a ma największą głębokość).

Zatem $B(T') \leq B(T)$, ale $B(T)$ jest najmniejsze możliwe, więc $B(T') = B(T)$ – czyli T' też reprezentuje optymalny kod prefiksowy.

Analogicznie zamieniamy miejscami liście y i b i otrzymujemy drzewo T'' reprezentujące optymalny kod prefiksowy, które ma żądane własności. $\square$

Z Lematu 1 wynika, że można zacząć konstruując optymalne drzewo połączeniem dwóch symboli o najmniejszej częstości.

Zachłanny wybór – w każdym kroku algorytm łączy dwa wierzchołki o najmniejszych kluczach.

Lemat 2. Niech A będzie alfabetem, a $f: A \rightarrow \mathbb{N}$ funkcją częstości. Niech x i y będą dwoma najrzadziej występującymi znakami w A . Niech $A' = (A \setminus \{x, y\}) \cup \{z\}$, gdzie $z \notin A$, i $f': A' \rightarrow \mathbb{N}$ będzie funkcją częstości taką, że:

- dla każdego $c \in A' \setminus \{z\}$: $f'(c) = f(c)$,

- $f'(z) = f(x) + f(y)$.

$|C'| = n - 1$. Z założenia indukcyjnego algorytm znajduje drzewo T' reprezentujące optymalny kod prefiksowy dla (A', f') .

Niech T będzie drzewem powstałym z T' poprzez zastąpienie liścia z wierzchołkiem wewnętrznym z dziećmi x i y .

T reprezentuje optymalny kod prefiksowy dla (A, f) .

Dowód. Dla $c \in A \setminus \{x, y\}$: $d_T(c) = d_{T'}(c)$, a $d_T(x) = d_T(y) = d_{T'}(z) + 1$.

Zatem:

$$\begin{aligned}
B(T) &= \sum_{c \in A} f(c) \cdot d_T(c) \\
&= \sum_{c \in A \setminus \{x, y\}} f(c) d_T(c) + f(x) d_T(x) + f(y) d_T(y) \\
&= \sum_{c \in A' \setminus \{z\}} f'(c) d_{T'}(c) + f(x)(d_{T'}(z) + 1) + f(y)(d_{T'}(z) + 1) \\
&= \sum_{c \in A' \setminus \{z\}} f'(c) d_{T'}(c) + d_{T'}(z)(f(x) + f(y)) + f(x) + f(y) \\
&= \sum_{c \in A'} f'(c) d_{T'}(c) + f(x) + f(y) \\
&= B(T') + f(x) + f(y)
\end{aligned}$$

Stąd:

$$B(T') = B(T) - f(x) - f(y)$$

Przypuśćmy, że T nie reprezentuje optymalnego kodu dla (A, f) . Niech T'' będzie drzewem reprezentującym optymalny kod prefiksowy dla (A, f) , tzn. $B(T'') < B(T)$.

Z Lematu 1 możemy wybrać T'' tak, aby x i y miały wspólnego rodzica i największą głębokość w T'' . Niech T''' będzie drzewem powstałym z T'' poprzez usunięcie liści x i y , nadanie ich rodzicowi etykiety z z kluczem $f(x) + f(y)$.

T''' reprezentuje kod prefiksowy dla (A', f') .

Takim samym obliczeniem jak wcześniej (zamieniając wszędzie T na T'' , T' na T''') pokazujemy, że $B(T''') = B(T'') - f(x) - f(y)$.

Mamy:

$$B(T''') = B(T'') - f(x) - f(y) < B(T) - f(x) - f(y) = B(T')$$

Sprzeczność z optymalnością T' dla (A', f') .

Zatem T reprezentuje optymalny kod dla (A, f) . □

Twierdzenie 1. Algorytm Huffmana konstruuje drzewo reprezentujące optymalny kod prefiksowy.

Dowód. Indukcja po n = liczba symboli w alfabecie C .

Dla $n = 1, 2$ – oczywiste.

Niech $n > 2$. Po pierwszej operacji łączenia dostajemy alfabet $C' = (C \setminus \{x, y\}) \cup \{z\}$ i funkcję $f': C' \rightarrow \mathbb{N}$ taką, że $f'(c) = f(c)$ dla wszystkich $c \in C' \setminus \{z\}$ i $f'(z) = f(x) + f(y)$, gdzie x i y są znakami z C o najmniejszych częstościach.

$|C'| = n - 1$. Z założenia indukcyjnego algorytm znajduje drzewo T' reprezentujące optymalny kod prefiksowy dla (C', f') .

Niech T będzie drzewem powstałym z T' poprzez zastąpienie liścia z wierzchołkiem wewnętrznym z dziećmi x i y . Z Lematu 2: T reprezentuje optymalny kod prefiksowy dla (A, f) . □